Retake Behavior and Score Recovery Analysis in Higher Education: Empirical Evidence from 123,696 Course Enrollments Using SQL, Inferential Statistics, and Survival Modeling

Nhóm 1 — Lớp AI2112 — Môn ADY201m
Trường Đại học FPT TP. Hồ Chí Minh, Học kỳ Fall 2026

Tháng 10 năm 2026

Tóm tắt nội dung

Nghiên cứu này phân tích toàn diện hành vi học lại/thi lại (*retake behavior*), mức độ cải thiện điểm số (*score recovery*) và xác suất phục hồi qua môn (*recovery probability*) trên bộ dữ liệu thực tế gồm 125.384 bản ghi điểm của 18 môn học Công nghệ Thông tin tại Trường Đại học FPT. Thông qua quy trình kiểm toán dữ liệu (*data forensics*), chúng tôi phát hiện và loại bỏ 1.653 bản ghi nhân bản hệ thống (đặc biệt là lỗi nhân bản danh sách lớp giữa kỳ `SP2018` và `SU2018`), chuẩn hóa 511 lỗi chính tả trạng thái và thu được 123.696 bản ghi sạch tương ứng với 101.965 cặp *(Sinh viên – Môn học)*. Kết quả thực nghiệm trên 22.713 trường hợp trượt lần đầu cho thấy $66,26\%$ (15.050 cặp) tiếp tục đăng ký học lại. Trong nhóm học lại có chấm điểm số ($n = 13.699$), điểm tổng kết trung bình tăng từ $2,81$ lên $4,92$ ($\Delta = +2,11$, $t = 91,09$, $p < 0,0001$, Cohen's $d = 0,78$), với $77,55\%$ cải thiện điểm số dương. Tuy nhiên, nghiên cứu chỉ ra **Nghịch lý Mức điểm – Độ tăng** (*Level-vs-Gain Paradox*): nhóm điểm gốc rất thấp ($< 2,0$) có độ tăng điểm thô lớn nhất ($\Delta = +3,26$) do hiệu ứng sàn nhưng lại có xác suất qua môn thấp nhất ($50,91\%$), trong khi nhóm trượt sát ngưỡng ($\geq 4,5$) chỉ tăng $+0,35$ điểm nhưng đạt tỷ lệ qua môn $69,33\%$. Phân tích sinh tồn (*Survival Analysis*) và 8 mô hình hồi quy/phân loại xác nhận rằng việc học lại ngay trong học kỳ (*Block 2*, Gap $= 0$) đạt xác suất phục hồi $76,61\%$ so với $57,82\%$ khi chờ sang kỳ kế tiếp ($\chi^2 = 575,89$, $p < 0,0001$), và xác suất qua môn có điều kiện giảm dần từ $60,66\%$ ở lần học thứ 2 xuống $48,60\%$ ở lần 3 và $38,02\%$ ở lần 4.

Từ khóa: Retake Behavior, Score Recovery, Recovery Probability, Level-vs-Gain Paradox, Discrete-Time Survival Analysis, Logistic Regression, ADY201m.

1 Giới thiệu và Định nghĩa Bài toán (Step 1: Understand the Problem)

Trong đào tạo đại học khối ngành Công nghệ Thông tin (CNTT), tỷ lệ trượt môn ở các học phần nền tảng lập trình và cấu trúc dữ liệu thường dao động từ 15% đến trên 45% [2, 4]. Mặc dù nhiều nghiên cứu trước đây đã tập trung vào bài toán cảnh báo sớm học vụ (*early warning systems*) hoặc dự đoán nguy cơ bỏ học [2, 3, 5, 12], phần lớn các công trình chỉ xem xét kết quả học tập tại một thời điểm tĩnh hoặc gộp các lần học lại như một bước tiền xử lý dữ liệu [4]. Rất ít nghiên cứu định lượng trực tiếp quỹ đạo chuyển trạng thái từ *trượt lần đầu* sang *phục hồi điểm số* ở các lần thi/học tiếp theo [1, 13, 15].

1.1 Phân biệt Ba Khái niệm Cốt lõi và Định nghĩa Toán học

Để tránh nhầm lẫn khái niệm trong phân tích thực nghiệm, nghiên cứu thiết lập định nghĩa toán học chặt chẽ cho ba khái niệm trên đơn vị quan sát là một cặp *(Sinh viên i, Môn học c)* với chuỗi điểm số theo thứ tự thời gian $S_{i,c,1}, S_{i,c,2}, \ldots, S_{i,c,K}$:

1. **Hành vi thi lại / học lại (Retake Behavior):** Đặc trưng bởi biến chỉ báo tiếp tục học lại sau khi trượt lần đầu $R_{i,c} = \mathbb{I}(K_{i,c} \geq 2 \mid \text{Fail}_{i,c,1} = 1)$, tổng số lần đăng ký $K_{i,c}$, khoảng cách thời gian giữa hai lần học $\Delta T_{i,c} = \text{SemIdx}_{i,c,2} - \text{SemIdx}_{i,c,1}$ (tính theo số học kỳ), và động cơ học lại (bắt buộc sau khi trượt *Mandatory Retake* so với tự nguyện cải thiện điểm *Voluntary Grade Improvement* khi đã qua môn ở lần 1).

2. **Mức độ phục hồi điểm số (Score Recovery):** Biến liên tục đo lường sự thay đổi điểm số giữa lần học lại và lần học gốc:

$$\Delta S_{i,c} = S_{i,c,2} - S_{i,c,1}, \qquad \Delta S_{i,c}^{\max} = \max_{k \geq 2} S_{i,c,k} - S_{i,c,1} \tag{1}$$

   Kết quả thay đổi được phân thành ba trạng thái: *Cải thiện* ($\Delta S_{i,c} > 0$), *Không đổi/Hòa* ($\Delta S_{i,c} = 0$), và *Giảm điểm* ($\Delta S_{i,c} < 0$).

3. **Xác suất phục hồi (Recovery Probability):** Vì tăng điểm dương (ví dụ từ $0,5$ lên $2,0$) không đồng nghĩa với việc hoàn thành môn học, chúng tôi định nghĩa ba tiêu chí phục hồi nhị phân:

   - *Tiêu chí A — Phục hồi qua môn ngay lần 2 (PassRec$_2$):* $\mathbb{I}(\text{Status}_{i,c,2} = \text{Passed} \mid \text{Fail}_{i,c,1} = 1, R_{i,c} = 1)$.
   - *Tiêu chí B — Phục hồi điểm có ý nghĩa học thuật (MeaningfulRec$_2$):* Đạt đồng thời trạng thái qua môn ($\text{Status}_{i,c,2} = \text{Passed}$, tức $\text{Total}_2 \geq 5,0$ và không bị điểm liệt) **và** mức tăng điểm tối thiểu $\Delta S_{i,c} \geq +1,0$ điểm trên thang 10.
   - *Tiêu chí C — Phục hồi tích lũy dài hạn (EverPass):* $\mathbb{I}(\max_{k \geq 2} \text{Pass}_{i,c,k} = 1 \mid \text{Fail}_{i,c,1} = 1)$.

1.2 Bốn Câu hỏi Nghiên cứu (Research Questions — RQ1 đến RQ4)

Dựa trên các biến thực tế tồn tại trong bộ dữ liệu 18 môn học và khoảng trống nghiên cứu từ 20 bài báo nền tảng [1, 4, 6, 15], dự án trả lời bốn câu hỏi nghiên cứu:

- **RQ1 (Phân phối hành vi học lại và phục hồi điểm số theo môn học):** Tỷ lệ trượt lần đầu, tỷ lệ tiếp tục học lại, phân phối độ lệch điểm $\Delta S = S_2 - S_1$ và tỷ lệ phục hồi qua môn khác biệt như thế nào giữa 18 môn học CNTT?
- **RQ2 (Nghịch lý Mức điểm – Độ tăng và các yếu tố quyết định phục hồi):** Hình thức trượt lần 1 (`Not Passed`, `Attendance Fail`, `Is Suspended`), dải điểm xuất phát S_1, điểm trung bình tích lũy trước đó (Prior GPA) và độ khó môn học liên hệ như thế nào với ΔS và xác suất qua môn $P(\text{PassRec}_2)$?
- **RQ3 (Ảnh hưởng của độ trễ thời gian và phân tích sinh tồn nhiều lần thi):** Khoảng cách học kỳ giữa hai lần học (ΔT) và số thứ tự lần học lại ($k = 2, 3, \ldots, 7$) tác động thế nào đến xác suất qua môn có điều kiện $h(k)$ và xác suất phục hồi tích lũy $1 - S(k)$?
- **RQ4 (Câu hỏi mở rộng Tuần 6 — Điểm nghẽn thi cuối kỳ so với thiếu hụt toàn diện):** Sự phân tách giữa điểm quá trình ($\text{Coursework}_1 \geq 5,0$) và điểm thi cuối kỳ ($\text{Final Exam}_1 < 4,0$) giúp phân biệt khả năng phục hồi của nhóm *Trượt do điểm liệt thi cuối kỳ (Exam Bottleneck)* với nhóm *Thiếu hụt học thuật toàn diện (Comprehensive Deficit)* và nhóm *Học cải thiện tự nguyện* ra sao?

Lưu ý Phương pháp luận về Nhân quả: Thiết kế dữ liệu hiện tại là dữ liệu quan sát dọc hồi cứu (*retrospective longitudinal observational data*). Mọi kết quả thống kê và mô hình dự đoán phản ánh **mối liên hệ thống kê (statistical association)** và **xác suất có điều kiện**, không tự động suy diễn thành quan hệ nhân quả (*causal effect*) nếu chưa có can thiệp ngẫu nhiên.

2 Tổng quan Tài liệu và Khoảng trống Nghiên cứu (RBL Literature Review)

Từ kho học liệu 20 bài báo khoa học (`P01`–`P20`), chúng tôi tổng hợp bốn nhóm phương pháp chính làm cơ sở đối sánh (*baseline*) cho dự án:

1. **Phân tích biến thiên điểm số nội cá thể (Within-Student Longitudinal Change):** Nghiên cứu P01 (2025) sử dụng kiểm định lặp (Repeated-Measures ANOVA) trên dữ liệu sinh viên qua hai học kỳ nhưng cỡ mẫu nhỏ ($n = 76$) và chưa mô hình hóa xác suất phục hồi sau khi trượt. Nghiên cứu P04 (2024) xử lý dữ liệu học vụ hơn 20 năm có chứa các môn học lại nhưng chỉ xem học lại là bước làm sạch dữ liệu thay vì biến mục tiêu.
2. **Dự báo cảnh báo sớm và vai trò của lịch sử điểm thành phần:** P02 (2023, bối cảnh đại học Việt Nam), P11 (2025) và P12 (2025) chứng minh điểm quá trình (*midterm/component scores*) và GPA tích lũy kỳ trước là các biến dự báo mạnh nhất cho kết quả cuối kỳ (ROC-AUC $> 0,90$).
3. **Ước lượng phân phối xác suất và tổ hợp mô hình máy học:** P06 (2024) nhấn mạnh sự cần thiết của xác suất có hiệu chỉnh (*calibrated probability*) thay vì chỉ dự báo điểm đơn lẻ; P07 (2024) và P08 (2026) thiết lập mô hình cơ sở Naive Bayes và Hồi quy tuyến tính (OLS), trong khi P05, P09, P10 và P13 sử dụng Logistic Regression, Random Forest và Gradient Boosting để phân loại sinh viên có nguy cơ và đánh giá tác động can thiệp.
4. **Mô hình chuyển trạng thái theo thời gian và phân tích sinh tồn:** P16 (2026) và P18 (2024) chỉ ra rằng khoảng cách thời gian giữa các sự kiện học tập mang thông tin dự báo quan trọng và đề xuất tiếp cận chuỗi trạng thái / phân tích sinh tồn (*Survival Analysis*).

3 Khảo sát Dữ liệu, Kiểm toán Lỗi và Làm sạch (Step 2: Data Understanding)

Bộ dữ liệu gốc (`tong_hop_mon_hoc.zip`) gồm 18 tệp Excel đại diện cho 18 môn học thuộc chương trình Cử nhân CNTT tại Trường Đại học FPT từ kỳ SP2017 đến SU2025 (26 học kỳ liên tiếp), với tổng cộng 125.384 dòng và 15.235 mã sinh viên ẩn danh (CODE).

3.1 Giải mã Mã môn học và Bảo mật Dữ liệu Cá nhân

Qua phân tích cấu trúc tên tệp, chúng tôi phát hiện quy tắc mã hóa tất định của mã môn học: mỗi cặp chữ số 01–26 ánh xạ sang chữ cái A–Z, và các chữ cái A–J ánh xạ sang chữ số 1–9, 0 (ví dụ: 010425BJA13 $\rightarrow$ ADY201m, 161806AIB $\rightarrow$ PRF192, 161815AIB $\rightarrow$ PRO192, 031904BJA $\rightarrow$ CSD201, 040209BJB $\rightarrow$ DBI202). Việc giải mã tên môn học giúp diễn giải chính xác tính chất học thuật (môn lập trình cơ sở, cấu trúc dữ liệu, đồ án hay thực hành lab), trong khi mã định danh sinh viên (CODE) được giữ nguyên trạng ẩn danh tuyệt đối để bảo vệ quyền riêng tư.

3.2 Ba Phát hiện Kiểm toán Dữ liệu Quan trọng (Data Forensics & Human Delta)

Quá trình kiểm tra chất lượng dữ liệu bằng Python phát hiện ba vấn đề trọng yếu mà nếu bỏ qua sẽ làm sai lệch hoàn toàn kết quả nghiên cứu:

1. **Phát hiện 1.653 bản ghi nhân bản hệ thống (SP2018 – SU2018 Roster Clone Bug):** Trong 6 môn học lớn (CEA201, CSD201, DBI202, OSG202, PRF192, PRO192), toàn bộ danh sách điểm của kỳ SP2018 bị xuất lặp nguyên vẹn sang kỳ SU2018 (trùng khớp 100% thứ tự NO., CODE, mọi cột điểm thành phần đến 4 chữ số thập phân và STATUS). Nếu không lọc bỏ, một thuật toán ngây thơ sẽ đếm nhầm hàng nghìn sinh viên đã qua môn ở SP2018 thành "học lại tự nguyện ở SU2018 với $\Delta S = 0$". Sau khi áp dụng quy tắc khử trùng lặp hai tầng (Rule A: trùng khớp tuyệt đối (COURSE_ID, NO., CODE, SCORE_SIG, STATUS); Rule B: trùng khớp vector điểm khác 0 trên cùng sinh viên–môn học), chúng tôi loại bỏ chính xác 1.653 dòng nhân bản (1.624 từ Rule A và 29 từ Rule B).

2. **Chuẩn hóa 511 lỗi chính tả nhãn trạng thái (STATUS) và 35 dòng rỗng:** Cột `STATUS` chứa 11 biến thể chuỗi do nhập liệu thủ công (`Passe`, `Pass`, `Not Passe`, `Attendance Fai`, `Attendance`, `Is Susspended`, `Is Susspende`). Chúng tôi ánh xạ toàn bộ về 5 trạng thái chuẩn (`Passed`, `Not Passed`, `Attendance Fail`, `Is Suspended`, `Is Exempt`) và loại bỏ 35 dòng trống không có mã sinh viên.

3. **Đặc thù môn thực hành `LAB211` (`120102BAA`) và thứ tự học lại trong cùng học kỳ (Block 1 $\rightarrow$ Block 2):** Môn `LAB211` (11.484 dòng gốc) đánh giá Đạt/Không đạt dựa trên số dòng lệnh (LOC) nên $96,6\%$ bản ghi không có điểm số `TOTAL` dạng số. Do đó, `LAB211` được giữ lại đầy đủ khi phân tích xác suất qua môn ($n = 15.050$ cặp học lại bắt buộc) và được tách riêng khi tính toán độ lệch điểm số liên tục ($n = 13.699$ cặp có đủ điểm số hai lần). Đồng thời, với các trường hợp học lại ngay trong cùng một học kỳ (học lại ở *Block 2* sau khi trượt *Block 1*, chiếm 3.677 cặp), bản ghi trượt được xếp trước bản ghi đạt để phản ánh đúng trình tự thời gian thực tế.

4 Kết quả Phân tích SQL và Thống kê Suy luận (Steps 3–5: Answering RQ1–RQ4)

Toàn bộ dữ liệu sạch (123.696 dòng trong bảng `enrollments` và 101.965 cặp trong bảng `retake_pairs`) được nạp vào hệ quản trị cơ sở dữ liệu quan hệ `SQLite3` (`retake_analysis.db`). Mọi kết quả truy vấn SQL đều được đối chiếu chéo 100% với thư viện `pandas` và `scipy.stats` trong Python.

4.1 Trả lời RQ1: Hành vi Học lại và Khả năng Phục hồi theo Môn học

Trên tổng số 101.965 cặp *(Sinh viên – Môn học)*, có 79.199 cặp qua môn ngay lần đầu ($77,67\%$), 53 cặp được miễn học ($0,05\%$), và 22.713 cặp trượt lần đầu ($22,28\%$; gồm 16.146 `Not Passed`, 6.162 `Attendance Fail` và 405 `Is Suspended`). Trong số 22.713 trường hợp trượt lần 1, có 15.050 trường hợp tiếp tục học lại ít nhất một lần (**tỷ lệ tiếp tục học lại đạt** $66,26\%$, KTC Wilson 95%: $[65,64\%; 66,87\%]$), trong khi 7.663 trường hợp ($33,74\%$) chưa ghi nhận lần học lại (bị kiểm duyệt phải / chuyển ngành / thôi học). Ngoài ra, chỉ có 137 trường hợp đã qua môn ở lần 1 ($\bar{S}_1 = 6,36$) tự nguyện đăng ký học cải thiện điểm ($\bar{S}_2 = 7,15$, $\overline{\Delta S} = +0,79$, tỷ lệ đạt lại $93,43\%$).

Trên 13.699 cặp học lại bắt buộc có điểm số liên tục, điểm tổng kết tăng trung bình $\overline{\Delta S} = +2,110$ điểm (SD $= 2,711$, trung vị $= +2,200$, IQR $= 3,900$). Kiểm định t bắt cặp (*Paired t-test*: $t = 91,093$, $p < 10^{-100}$, cỡ hiệu ứng Cohen's $d = 0,778$) và kiểm định phi tham số Wilcoxon signed-rank ($W = 11.575.448,5$, $p < 10^{-100}$) đều xác nhận mức tăng điểm có ý nghĩa thống kê rất lớn. Về phân loại chiều hướng thay đổi: $77,55\%$ **tăng điểm** ($\Delta S > 0$), $3,28\%$ **giữ nguyên điểm** ($\Delta S = 0$), và $19,16\%$ **giảm điểm** ($\Delta S < 0$). Tính chung toàn bộ 15.050 cặp học lại bắt buộc, xác suất qua môn ngay lần 2 là $60,66\%$ ($[59,88\%; 61,44\%]$) và xác suất qua môn tích lũy sau tất cả các lần học là $79,06\%$ ($[78,40\%; 79,70\%]$).

4.2 Trả lời RQ2: Nghịch lý Mức điểm – Độ tăng (Level-vs-Gain Paradox) và Hình thức Trượt

Bảng 2 trình bày kết quả phân tích chéo giữa hình thức trượt lần 1 và dải điểm xuất phát S_1. Kiểm định Kruskal-Wallis xác nhận sự khác biệt có ý nghĩa thống kê cao về ΔS giữa ba nhóm trạng thái trượt ($H = 194,27$, $p = 6,53 \times 10^{-43}$), và kiểm định Chi-bình phương xác nhận sự phân hóa mạnh về xác suất qua môn ($\chi^2 = 446,80$, df $= 2$, $p = 9,53 \times 10^{-98}$):

- **Trượt điểm danh (`Attendance Fail`, $n = 3.107$):** Có xác suất qua môn ở lần 2 thấp nhất, chỉ đạt $44,35\%$ (tích lũy đạt $64,40\%$), mặc dù độ tăng điểm trung bình đạt $+2,92$ điểm (từ $0,86$ lên $3,74$). Nguyên nhân là do sinh viên nghỉ học quá 20% số tiết ở lần 1 bị cấm thi cuối kỳ ($S_1 \approx 0,86$), nên dù lần 2 có đi thi thì hơn một nửa vẫn không đạt ngưỡng $5,0$.

Bảng 1: Tổng hợp hành vi học lại, độ lệch điểm số và xác suất phục hồi trên các môn học tiêu biểu (Truy vấn SQL 1)

Mã ẩn	Mã môn	Tên môn học	Số SV	Trượt L1 (%)	Học lại (n)	$\bar{S}_1$	$\bar{S}_2$ ($\overline{\Delta S}$)	Qua L2 / Tích lũy
161806AIB	PRF192	Programming Fundamentals (C)	12.789	28,91%	2.598	2,95	5,07 (+2,12)	61,70% / 81,95%
161815AIB	PRO192	OOP with Java	11.076	26,41%	2.355	2,80	5,01 (+2,21)	63,95% / 86,16%
031904BJA	CSD201	Data Structures & Algorithms	9.405	25,19%	1.711	2,87	5,38 (+2,51)	65,11% / 79,31%
040209BJB	DBI202	Intro to Databases	11.422	20,57%	1.616	2,47	4,56 (+2,09)	60,83% / 80,07%
161810CJA	PRJ301	Java Web App Development	3.867	48,75%	1.380	2,48	4,64 (+2,16)	56,52% / 80,43%
120102BAA	LAB211	OOP with Java Lab (LOC)	9.543	22,44%	1.359	N/A	N/A (Pass/Fail)	61,52% / 78,81%
151907BJB	OSG202	Operating Systems	11.661	13,74%	975	3,76	4,91 (+1,14)	55,79% / 77,74%
161810CJ24	PRJ30x	Java Web Development (Merged)	3.842	35,40%	911	2,72	4,80 (+2,08)	56,97% / 65,64%
030501BJA	CEA201	Computer Org. & Architecture	14.044	13,43%	843	3,48	5,07 (+1,59)	61,80% / 74,97%
161810CBA	PRJ321	Web-Based Java Apps (Legacy)	1.596	53,95%	562	1,26	3,48 (+2,22)	47,86% / 64,77%
091520AJB	IOT102	Internet of Things	8.592	9,28%	317	2,21	5,49 (+3,29)	68,45% / 81,39%
031904BJC	CSD203	Advanced DSA (Python)	984	40,35%	271	3,67	5,60 (+1,93)	53,14% / 69,37%
160616AIA	PFP191	Programming Fund. (Python)	1.304	19,02%	101	2,67	4,92 (+2,25)	55,45% / 69,31%
010425BJA13	ADY201m	AI & DS with Python & SQL	780	5,38%	21	3,37	5,34 (+1,97)	71,43% / 76,19%
040116CIA13	DAP391m	Data Analytics Project	694	4,61%	16	2,28	6,76 (+4,49)	81,25% / 87,50%
Tổng / TB	**18 môn**	**Toàn bộ dữ liệu sạch**	**101.965**	**22,28%**	**15.050**	**2,81**	**4,92 (+2,11)**	**60,66% / 79,06%**

- **Trượt học thuật (`Not Passed`, $n = 11.603$):** Đạt xác suất qua môn ở lần 2 là $64,66\%$ (tích lũy $82,78\%$). Đặc biệt, khi xét theo dải điểm xuất phát trong nhóm `Not Passed`: nhóm điểm rất thấp ($S_1 < 2,0$) tăng trung bình $+3,26$ điểm nhưng chỉ có $50,91\%$ qua môn; ngược lại, nhóm trượt sát ngưỡng ($S_1 \geq 4,5$, thường do điểm thi cuối kỳ $< 4,0$) chỉ tăng trung bình $+0,35$ điểm nhưng đạt tỷ lệ qua môn tới $69,33\%$ ở lần 2 và $85,79\%$ tích lũy.

Bảng 2: Nghịch lý Mức điểm – Độ tăng theo hình thức trượt và dải điểm lần 1 (Truy vấn SQL 2)

Hình thức trượt L1	Dải điểm gốc (S_1)	Số cặp (n)	$\bar{S}_1$	$\bar{S}_2$	$\overline{\Delta S}$	Qua L2 (%)	Qua tích lũy (%)
Attendance Fail	0. Mất điểm số (LAB211)	508	N/A	N/A	N/A	51,18%	69,09%
Attendance Fail	1. Rất thấp ($< 2,0$)	2.233	0,51	3,63	+3,12	40,80%	63,50%
Attendance Fail	2. Thấp ($2,0 - 3,49$)	270	2,61	4,62	+2,02	55,93%	70,37%
Attendance Fail	3. Cận ngưỡng ($3,5 - 4,49$)	70	3,84	5,21	+1,36	60,00%	71,43%
Is Suspended	Toàn nhóm bị đình chỉ thi	340	3,64	5,84	+2,20	73,24%	91,18%
Not Passed	0. Mất điểm số (LAB211)	812	N/A	N/A	N/A	69,33%	85,10%
Not Passed	1. Rất thấp ($< 2,0$)	2.585	0,86	4,13	+3,26	50,91%	71,95%
Not Passed	2. Thấp ($2,0 - 3,49$)	3.057	2,73	5,42	+2,69	68,40%	84,99%
Not Passed	3. Cận ngưỡng ($3,5 - 4,49$)	1.983	3,95	5,42	+1,46	67,47%	85,53%
Not Passed	4. Sát ngưỡng ($\geq 4,5$)	3.166	5,24	5,60	+0,35	69,33%	85,79%

4.3 Trả lời RQ3: Độ trễ Thời gian Học lại (ΔT) và Quỹ đạo Sinh tồn Nhiều lần thi

Kiểm định trên 5 nhóm khoảng cách học kỳ ($\Delta T = \text{SemIdx}_2 - \text{SemIdx}_1$) cho thấy việc học lại ngay lập tức trong học kỳ (**Same Semester / Block 2**, $\Delta T = 0$, $n = 3.677$) mang lại tỷ lệ qua môn lần 2 vượt trội đạt $76,61\%$ ($\overline{\Delta S} = +2,94$, tích lũy $87,57\%$). Khi trì hoãn sang học kỳ kế tiếp ($\Delta T = 1$, $n = 7.437$), tỷ lệ qua môn giảm xuống $57,82\%$ ($\overline{\Delta S} = +1,90$); trì hoãn 2 học kỳ ($\Delta T = 2$, $n = 1.759$) giảm còn $49,91\%$; và trì hoãn 1 năm ($\Delta T = 3$–4, $n = 1.512$) đạt $50,26\%$ ($H = 591,33, p < 10^{-120}$; $\chi^2 = 575,89, p < 10^{-120}$).

4.4 Trả lời RQ4 (Mở rộng Tuần 6): Điểm nghẽn Thi cuối kỳ (Exam Bottleneck) vs. Thiếu hụt Toàn diện

Khi phân tách điểm quá trình (Coursework_1) và điểm thi cuối kỳ (Final Exam_1) trên 13.699 cặp học lại bắt buộc và 137 cặp học cải thiện, chúng tôi xác định bốn hồ sơ sinh viên rõ rệt:

1. **Nhóm 1 — Mất gắn kết chuyên cần (`Attendance Fail`, $n = 2.599$):** Điểm quá trình thấp ($1,53$), điểm thi cuối kỳ bằng $0,00$; xác suất qua môn lần 2 chỉ đạt $43,02\%$.
2. **Nhóm 2 — Thiếu hụt học thuật toàn diện ($\text{Coursework}_1 < 5,0$, $n = 5.798$):** Điểm quá trình trung bình $2,68$, điểm thi cuối kỳ $1,67$; xác suất qua môn lần 2 đạt $60,45\%$ (tích lũy $78,25\%$).
3. **Nhóm 3 — Điểm nghẽn thi cuối kỳ ($\text{Coursework}_1 \geq 5,0$ nhưng trượt do điểm liệt thi cuối kỳ, $n = 5.302$):** Có nền tảng quá trình tốt ($\overline{\text{CW}}_1 = 7,12$) nhưng vấp ngã ở kỳ thi cuối kỳ ($\overline{\text{FE}}_1 = 2,63$); nhóm này đạt xác suất qua môn lần 2 cao nhất trong các nhóm trượt là $69,28\%$ và xác suất qua môn tích lũy đạt $87,14\%$.
4. **Nhóm 4 — Học cải thiện tự nguyện (Đã `Passed` lần 1, $n = 137$):** Điểm gốc $\bar{S}_1 = 6,36$, điểm lần 2 tăng lên $\bar{S}_2 = 7,15$ ($\overline{\Delta S} = +0,79$), với $73,88\%$ cải thiện điểm dương và $93,43\%$ giữ vững trạng thái qua môn.

5 Phân tích Hồi quy, Phân loại Xác suất và Mô hình Sinh tồn (Step 6: 8 Models)

Để đáp ứng và vượt yêu cầu tối thiểu 5 mô hình của môn ADY201m, chúng tôi xây dựng và đánh giá 8 **mô hình thống kê và máy học** trên tập dữ liệu học lại có điểm số ($n = 13.699$, chia ngẫu nhiên có phân tầng 80% Train $= 10.959$ và 20% Test $= 2.740$, chuẩn hóa biến đầu vào hoàn toàn trên tập Train để chống rò rỉ dữ liệu *data leakage*). Mười một biến đầu vào đều là các thông tin đã biết **trước khi** kỳ thi lần 2 diễn ra: `TOTAL_1`, `COURSEWORK_IMP`, `FINAL_EXAM_IMP`, `IS_AF_1`, `IS_SUSP_1`, `IS_IMMEDIATE_RETAKE`, `LOG_SEM_GAP`, `COURSE_FAIL_RATE`, `COURSE_MEAN_TOTAL`, `PRIOR_GPA_IMP`, và `CUM_FAILS_BEFORE`.

Bảng 3: So sánh hiệu năng 8 mô hình Hồi quy, Phân loại xác suất và Sinh tồn trên tập kiểm thử (Holdout Test Set)

Mã MH	Tên Mô hình & Phương pháp	Biến mục tiêu	RMSE / Acc	MAE / F1	R^2 / AUC	Brier Score
Nhóm A: Các mô hình Hồi quy dự báo mức thay đổi điểm liên tục ($\Delta S = TOTAL_2 - TOTAL_1$)						
Baseline 0	Mô hình Trung bình (Null Mean Baseline)	$\Delta S \in \mathbb{R}$	2,6961	2,1734	$-0,0003$	N/A
Model 1	Hồi quy Tuyến tính Đơn ($\Delta S \sim$ TOTAL$_1$, `P08`)	$\Delta S \in \mathbb{R}$	2,4585	2,0158	0,1683	N/A
Model 2	Hồi quy Tuyến tính Đa biến (OLS 11 biến, `P08`)	$\Delta S \in \mathbb{R}$	2,3138	1,8616	0,2633	N/A
Model 3	Hồi quy Đa thức Tương tác bậc 2 + Ridge L2 ($\alpha = 50$)	$\Delta S \in \mathbb{R}$	**2,2792**	**1,8244**	**0,2852**	N/A
Model 4	Random Forest Regressor (40 cây quyết định, $d = 7$)	$\Delta S \in \mathbb{R}$	2,2811	1,8288	0,2840	N/A
Nhóm B: Các mô hình Phân loại & Sinh tồn ước lượng xác suất qua môn ($P(Pass = 1 \mid \mathbf{x})$)						
Model 5	Gaussian Naive Bayes Classifier (Baseline `P07`)	Pass$_2 \in \{0, 1\}$	66,57%	0,7351	0,6916	0,2524
Model 6	Hồi quy Logistic Đa biến (L2 MLE, `P01/P12`)	Pass$_2 \in \{0, 1\}$	67,01%	0,7569	0,7111	0,2073
Model 7	Random Forest Classifier (50 cây quyết định, `P05/P09`)	Pass$_2 \in \{0, 1\}$	**68,50%**	**0,7643**	**0,7340**	**0,2003**
Model 8	Mô hình Sinh tồn Rời rạc Cox / Cloglog (Attempts 2..7, `P16`)	$h(k \mid \mathbf{x}) \in (0, 1)$	67,44%	0,7207	0,7295	0,2090

5.1 Giải thích Ý nghĩa Thống kê của Hệ số Hồi quy OLS, Odds Ratio và Hazard Ratio

So sánh các hệ số chuẩn hóa giữa **Model 2 (Multiple OLS cho ΔS)**, **Model 6 (Logistic Regression cho Pass$_2$)** và **Model 8 (Discrete-Time Cox / Cloglog Survival cho $h(k)$)** làm sáng tỏ cơ chế vận hành của việc phục hồi điểm số:

1. **Điểm gốc lần 1 (`TOTAL_1`):** Trong Model 2 (OLS), `TOTAL_1` có hệ số âm ($\beta = -1,3079, t = -25,55, p < 0,0001$) do hiệu ứng sàn (*floor effect*): người có điểm lần 1 càng thấp thì khoảng trống để tăng điểm (ΔS) càng lớn. Ngược lại, trong Model 6 (Logistic) và Model 8 (Cox Survival), `TOTAL_1` có hệ số dương rất mạnh (OR $= 1,288, z = +5,24, p = 1,63 \times 10^{-7}$; HR $= 1,199$), khẳng định sinh viên có nền tảng điểm lần 1 cao hơn có xác suất vượt ngưỡng $5,0$ để qua môn cao hơn hẳn.

2. **Điểm trung bình tích lũy kỳ trước (`PRIOR_GPA_IMP`):** Là yếu tố năng lực nội tại mạnh nhất thúc đẩy cả mức tăng điểm ($\beta = +0,5286, t = +18,06, p < 0,0001$), xác suất qua môn lần 2 (OR $= 1,416$ cho mỗi độ lệch chuẩn tăng thêm, $z = +12,18, p < 0,0001$) và tốc độ phục hồi sinh tồn (HR $= 1,299$).

3. **Học lại ngay trong kỳ (`IS_IMMEDIATE_RETAKE`) và Độ trễ (`LOG_SEM_GAP`):** Học lại ngay trong Block 2 làm tăng $+0,3739$ điểm phục hồi ($t = +10,39$) và tăng tỷ lệ cược qua môn thêm $39,7\%$

(OR $= 1,397, z = +9,85, p < 0,0001$), trong khi kéo dài khoảng cách chờ đợi làm suy giảm đáng kể cơ hội phục hồi (OR $= 0,875, p = 4,49 \times 10^{-5}$; HR $= 0,805$).

4. **Trượt điểm danh (`IS_AF_1`) và Độ khó môn học (`COURSE_FAIL_RATE`):** Trượt do nghỉ học quá quy định làm giảm xác suất qua môn ở lần học lại (OR $= 0,852, z = -6,58, p < 10^{-10}$), và các môn học có tỷ lệ trượt cơ sở cao làm giảm đáng kể xác suất phục hồi (OR $= 0,769, z = -4,62, p = 3,78 \times 10^{-6}$).

5. **Bảng Sinh tồn Kaplan–Meier (Model 8):** Xác suất qua môn có điều kiện $h(k)$ giảm đơn điệu theo số lần thi lại: Lần học thứ 2 ($k = 1$): $60,66\%$ ($S(1) = 39,34\%$ còn trượt); Lần 3 ($k = 2$): $48,60\%$ (phục hồi tích lũy $1 - S(2) = 79,78\%$); Lần 4 ($k = 3$): $38,02\%$ ($1 - S(3) = 87,47\%$); Lần 5 ($k = 4$): $30,21\%$ ($1 - S(4) = 91,25\%$); Lần 6 ($k = 5$): $30,52\%$; và Lần 7 ($k = 6$): $21,90\%$.

6 Thảo luận, Hạn chế và Khuyến nghị Học vụ (Discussion & Limitations)

6.1 Hạn chế của Dữ liệu và Phương pháp (Limitations)

Nghiên cứu tuân thủ nguyên tắc minh bạch khoa học và ghi nhận rõ bốn giới hạn: (1) *Kiểm duyệt phải (Right-Censoring):* Có 7.663 trường hợp trượt lần đầu (đặc biệt ở các học kỳ cuối `SP2025`, `SU2025`) chưa phát sinh bản ghi học lại trong cửa sổ quan sát; (2) *Thiếu biến hành vi vi mô (LMS logs):* Dữ liệu không có số giờ tự học, tần suất đăng nhập LMS hay yếu tố kinh tế – xã hội như trong `P14, P18`; (3) *Giới hạn giải thích phương sai ($R^2 = 0,2852$, ROC-AUC $= 0,7340$):* Khoảng 71% phương sai của sự thay đổi điểm số phụ thuộc vào nỗ lực ôn tập thực tế của sinh viên ở kỳ học lại chứ không tiền định hoàn toàn bởi điểm quá khứ; và (4) *Môn* `LAB211`*:* Không lưu điểm tổng kết số nên chỉ tham gia vào mô hình xác suất qua môn mà không tham gia hồi quy điểm số liên tục.

6.2 Khuyến nghị Chính sách Đào tạo cho Trường Đại học

Từ bằng chứng thực nghiệm trên 123.696 bản ghi, nhóm nghiên cứu đề xuất ba giải pháp thực tiễn:

- **Ưu tiên xếp lịch học lại ngay trong Block 2 (Immediate Retake):** Vì học lại ngay trong kỳ giúp đạt tỷ lệ qua môn $76,61\%$ (cao hơn gần 19 điểm phần trăm so với chờ sang kỳ sau và $26,7$ điểm phần trăm so với chờ 2 kỳ), nhà trường nên tự động gợi ý đăng ký lớp Block 2 ngay khi sinh viên nhận kết quả trượt Block 1.
- **Phân luồng can thiệp theo Hồ sơ Trượt (RQ4):** Với nhóm *Điểm nghẽn thi cuối kỳ* (Coursework $\geq 5,0$ nhưng trượt Final Exam, $n = 5.302$), tỷ lệ phục hồi rất cao ($69,28\%$ ở lần 2 và $87,14\%$ tích lũy), do đó chỉ cần tổ chức lớp ôn tập trọng tâm kỹ năng làm bài thi cuối kỳ/thực hành. Ngược lại, nhóm *Trượt điểm danh (*`Attendance Fail`*)* chỉ đạt $43,02\%$ qua môn khi học lại và cần có sự can thiệp tư vấn học vụ bắt buộc về kỷ luật chuyên cần.
- **Ngưỡng cảnh báo đỏ sau Lần thi thứ 3:** Phân tích sinh tồn cho thấy sau lần học thứ 3 không đạt (bước sang lần học thứ 4), xác suất qua môn có điều kiện rơi xuống dưới 40% ($38,02\%$). Đây là ngưỡng vàng để Phòng Quản lý Đào tạo kích hoạt cơ chế kèm cặp $1:1$ (*mandatory tutoring*).

Tài liệu

[1] Riyadh Elm University Longitudinal Study (2025). *Factors influencing students' grade point average variations across the first and second semesters: A retrospective observational study*. Archive P01 in ADY201m RBL Corpus.

[2] Vietnamese Higher Education Early Warning Study (2023). *Academic performance warning system based on data driven for higher education (APWD Dataset)*. Archive P02 in ADY201m RBL Corpus.

[3] KSA Bachelor Performance Study (2024). *Early prediction of student academic performance based on machine learning algorithms*. Archive P03 in ADY201m RBL Corpus.

[4] King Saud University 20-Year Longitudinal Study (2024). *A comparative analysis for GPA prediction of undergraduate students using machine and deep learning*. Archive P04 in ADY201m RBL Corpus.

[5] AI-Driven Dropout Benchmark Study (2026). *Artificial intelligence-driven early prediction of student dropout and academic outcomes in higher education*. Archive P05 in ADY201m RBL Corpus.

[6] Course Grade Distribution Prediction Study (2024). *A novel grades prediction method for undergraduate students by learning explicit conditional distribution*. Archive P06 in ADY201m RBL Corpus.

[7] Probabilistic Student Classifier Study (2024). *Use of the Naive Bayes classifier algorithm in machine learning for student performance prediction*. Archive P07 in ADY201m RBL Corpus.

[8] Linear Regression Baseline Study (2026). *Performance of linear regression in predicting academic outcome*. Archive P08 in ADY201m RBL Corpus.

[9] Paramedical Academic Performance Study (2026). *Applying machine learning models to predict and identify factors affecting academic performance*. Archive P09 in ADY201m RBL Corpus.

[10] University EDM Benchmark Study (2025). *Analysis of factors affecting the academic performance of university students using machine learning*. Archive P10 in ADY201m RBL Corpus.

[11] Cumulative GPA and Recent Exam Study (2025). *Investigating cumulative GPA, last course exam grade, and licensure success: A correlational study*. Archive P11 in ADY201m RBL Corpus.

[12] Midterm Early Detection Study (2025). *Early detection of at-risk health sciences students: A machine learning-based predictive study using midterm grades*. Archive P12 in ADY201m RBL Corpus.

[13] SPPA Learning Analytics Intervention Study (2025). *Evaluating the student performance prediction and action framework through a learning analytics intervention study*. Archive P13 in ADY201m RBL Corpus.

[14] Explainable ML Corrective Action Framework (2024). *Framework for suggesting corrective actions to help students at risk of low performance using explainable ML*. Archive P14 in ADY201m RBL Corpus.

[15] Temporal Trajectory & Survival Study (2026). *Interpretable undergraduate dropout prediction via explainable boosting and Gaussian Hidden Markov Models*. Archive P16 in ADY201m RBL Corpus.

[16] Temporal Interaction Graph Study (2024). *Enhancing academic performance prediction with temporal graph networks*. Archive P18 in ADY201m RBL Corpus.